



Text2SQL im Vergleich:

Frontier Models, Open Weights und Fine-Tuning


Data2Day
08.10.2026

Dr. Björn Buchhold
CID GmbH

Text2SQL im Vergleich

Ein 4B-Modell schlägt Gemini und Grok.

Solange niemand das Glossar zeigt



Text2SQL ist mehr als SQL

„Wie viele aktive Kunden gibt es aktuell?“

Allgemeine Interpretation

| Konto nicht gelöscht

Unsere Definition

| Konto nicht gelöscht

| Bestellung in 90 Tagen

| nicht storniert

Beides ist plausibel. Nur eines ist bei uns richtig.

Welche Antwort ist richtig?

„Berechne für alle Maschinen die Ausfallquote.“

- ID?
- Name?
- ID und Name?

Bevor wir Modelle vergleichen, müssen wir „richtig“ definieren.



Text2SQL ist ein Grounding-Problem



Schema

Tabellen, Spalten, Relationen kennen

z.B. Tabelle „machines“ hat Spalte „machine_name“, nicht „title“



Geschäftsregeln

Fachbegriffe korrekt in Filter uebersetzen

z.B. „aktiv“ = Bestellung $\leq$ 90 Tage, nicht nur „Konto vorhanden“



Ergebnisvertrag

Erwartete Felder und Format einhalten

z.B. „Maschinen-ID“ erwartet, nicht „Maschinenname“



Text2SQL Benchmarks

Benchmark	Was wird schwieriger?	Was gilt als richtig?
Spider 1.0	Unbekannte Schemata	Test-Suite-Accuracy
BIRD	Datenwerte + Zusatzwissen	Execution Accuracy
Spider 2.0	Enterprise-Workflows + Tools	Aufgabenspezifische Tests
LiveSQLBench	Große Schemas + neue, versteckte Aufgaben	Ausführbare Test Cases

“Accuracy” bedeutet in jedem dieser Benchmarks etwas anderes.

Was wir bereits untersucht haben

- 2 Datensätze:
 - MES (Manufacturing Execution System)
 - selbst generiert (LLM & manuelles Review für Eval)
 - Training & Evaluation (in distribution)
 - Hospital
 - selbst generiert, nur out-of-distribution Evaluation
- Sonnet 4.6 vs Qwen3-4B
 - Qwen3-4B: SFT & RLVR (GRPO)

“

How many production orders have critical priority?

“

Which machines had more unplanned than planned maintenance events, and what was the total downtime for each?

“


How many patients from each city have had at least one abnormal lab result?

“


Find the top 3 doctors by total dosage (in mg) of medications they prescribed, showing their full name and total dosage rounded to 1 decimal place.

SFT erzeugt starke Spezialisten

In Domain: MES



Out of Domain: Hospital



Aufbau der neuen Evaluation

180 manuell geprüfte deutsche Fragen · englisches E-Commerce-Schema · erwartete Ergebnisfelder explizit

Bekannte Fragefamilien

60 Fragen

- easy: 20
- medium: 20
- hard: 20

Komposition

60 Fragen

- easy: 20
- medium: 20
- hard: 20

Terminologie

60 Fragen

- easy: 20
- medium: 20
- hard: 20

P0

Nur Schema


P1

Schema + Geschäftsregeln


SQL in BigQuery ausführen

Ergebnis mit Gold vergleichen

Frontier-Models brauchen Glossar




SFT macht ein 4B-Modell konkurrenzfähig




SFT lernt vor allem Hausbegriffe

Qwen 3.5 4B · P0: nur Schema · Vanilla vs. SFT

Schema-nahe wörtliche Begriffe (n=81)



Hausbegriffe / Geschäftsregeln (n=97)



„Wie viele aktive Kunden gibt es je Kundensegment?“

Hausdefinition: aktiv =

- Konto nicht gelöscht
- mindestens eine nicht stornierte Bestellung
- in den letzten 90 Tagen

Vanilla

```
WHERE deleted_at IS NULL
```


SFT

```
WHERE deleted_at IS NULL  
AND order_status != 'cancelled'  
AND order_date >= Stichtag - 90 Tage
```

Mehrstufiges SQL bleibt schwer

Qwen 3.5 4B · P0: nur Schema · Vanilla vs. SFT

● Vanilla ● SFT



Beispiel aus der Evaluation

„Wie hat sich die kumulierte Anzahl an Bestellungen im ersten Halbjahr 2026 entwickelt? Gib je Monat den Jahr-Monat, die Bestellungen des Monats und die laufende Summe aus.“


Benötigt: erst monatlich aggregieren, dann laufende Summe

1. WITH monthly AS (COUNT(*) GROUP BY month)
2. SUM(order_count) OVER (ORDER BY month)

Modell (SFT): beides in einem Schritt verschachtelt

```
SUM(COUNT(order_id)) OVER (ORDER BY order_date)
```


27B löst auch schwierige Aufgaben



PRAXISEMPFEHLUNG

Nicht jedes Warehouse sollte direkt befragt werden

Wenn das Modell zwischen Hunderten Tabellen und Tausenden Spalten suchen muss, ist vielleicht die Schnittstelle das Problem.



Den Datenraum begrenzen, bevor man das Modell optimiert.

Fine-Tuning lohnt sich – in bestimmten Fällen

01**SFT FUNKTIONIERT**

Auch bei kleinen Modellen

49 → 101 von 180 (Qwen 4B, nur Schema)

Qwen3.8-27B schlägt Frontier-Modelle

02**SFT SPEZIALISIERT**

Das Modell lernt das Unternehmen

*Größte Gains bei
Hausbegriffen & Geschäftsregeln (3 → 45)*

03**SFT VERÄNDERT DEN
BUSINESS CASE**

Kleine Modelle werden konkurrenzfähig

Serving bleibt eigene Aufgabe

Kleineres Modell

lokal / privat betreibbar

mehr Kosten- & Throughput-Potenzial

Nicht das beste Modell bauen, sondern das kleinste Modell, das den eigenen Use Case zuverlässig löst.

Contact, Code & Q&A



Dr. Björn Buchhold


Technology Evangelist (AI) @ CID GmbH



<https://www.linkedin.com/in/bbuchhold/>



b.buchhold@cid.com



Code

<https://github.com/Buchhold/text2sql-talk-reproducibility>



Reproduce results



Modify, adapt, and use



No ready-to-use library or general solution

**Backup slides
after this one**



Backup plot

Gemma / Qwen mit thinking

Text2SQL im Vergleich

Ein 4B-Modell schlägt Gemini und Grok.


Solange niemand das Glossar zeigt.




Gleicher P0-Kontext, kein Glossar • Werte vorläufig, finale Runs stehen noch aus

Zwei Ebenen der Evaluation

Deutsche Fragen · englisches E-Commerce-Schema · erwartete Ergebnisfelder explizit



Wer ist CID?



1997 gegründet ♦ 12 Länder ♦ 300 Mitarbeiter ♦ 15 Standorte ♦
inhabergeführt ♦ in privater Hand ♦ 19+ Jahre KI ♦ Rhein-Main HQ